Résolution des schémas Winograd en français : approche deep-learning et approche sémantique

La résolution des schémas Winograd est une version particulière de la tâche de résolution d'anaphores, conçue comme un défi pour la communauté dans la mesure où la résolution suppose la prise en compte de raisonnement sur les connaissances du monde (Levesque et al., 2012). Un schéma Winograd est constitué d'une paire de discours identiques à un mot (ou une expression) près. La tâche consiste en la résolution d'une expression anaphorique dont l'antécédent change d'une version à l'autre. Ainsi dans (1), la réponse naturelle pour la question formée avec le mot *weak* est *the man* (R0), alors que la question formée avec le mot *heavy* appelle plutôt la réponse *his son* (R1).

(1) The man (R0) couldn't lift his son (R1) because he was so [weak/*heavy*].
Who was [weak/heavy]?

Dans l'article de (Seminck et al., 2019), un modèle Long Short Term Memory (LSTM) et un modèle Context2vec (C2V) ont été entraînés sur une version de Wikipédia en 2016 (cf. (Coavoux, 2017)). Le premier modèle calcule la probabilité de 288 phrases générées à partir de 144 schémas traduits en français (Amsili & Seminck, 2017b) en remplaçant le pronom par les réponses possibles. Le deuxième, reposant sur des réseaux de neurones récurrents bidirectionnels, évalue laquelle des deux réponses correspond le mieux au contexte. Les auteurs ont proposé 3 mesures : *exactitude* (proportion des réponses correctes totales), *qualité* (proportion des réponses correctes dans le cas où il y a une réponse) et *réussite* (mesure synthétique prenant en compte les cas de non réponse), cette dernière censée être une mesure plus pertinente que le score F1. Sur le plan de la réussite, les résultats d'une méthode simple basée sur calcul de l'information mutuelle (PMI, Shannon, 1948)) sur le corpus FrWac (Baroni et al., 2009) ont été pris comme référence.

La réussite a été de 50.93 % dans le cas de LSTM et 52.34% pour C2V, alors que la méthode basée sur PMI a atteint une réussite de 53.63%. La performance état de l'art sur ces 144 schémas était donc 53.63 % et cette performance a été obtenue avec une méthode initialement utilisée pour calculer le degré de non associativité (Amsili & Seminck, 2017a). Ces résultats ont conduit les auteurs à conclure que « l'approche par modèle de langue des schémas Winograd reste limitée, sans doute parce que les modèles de langue encodent très difficilement le genre de raisonnement nécessaire à la résolution des schémas Winograd ».

Cependant les approches dans le domaine des plongements lexicaux ont évolué. Si les premiers modèles contextuels basés sur des architectures LSTM ont permis un gain de performance considérable, les nouveaux modèles neuronaux du type Bert ont évolué vers des architectures de type Transformer avec d'importantes conséquences sur la méthodologie adoptée dans diverses tâches en TAL (il est aujourd'hui courant de ne pas construire des modèles à partir de zéro mais de faire du fine-tuning sur des modèles pré-entraînés). La communauté Winograd est aussi consciente de ces évolutions et les résultats récents sur Winograd en anglais sont encourageants. Le Tableau 1 offre une vue globale sur l'évolution de performance sur les schémas Winograd en anglais.

Auteur	Approche	Exactitude
(Q. Liu et al., 2016)	Knowledge enhanced embedding (KEE)	52.8
(Emami et al., 2018)	Extraction de connaissances à partir des requêtes	57.1
(Trinh & Le, 2018)	Ensemble de 14 modèles de langue	63.6
(Kocijan et al., 2019)	BERT entraîné sur le corpus DPR (Rahman & Ng, 2012)	72.5
(Sakaguchi et al., 2020)	RoBERTa (Y. Liu et al., 2019) entraîné sur le corpus DPR	83.1
(Sakaguchi et al., 2020)	RoBERTa entraîné sur un corpus de 44000 problèmes	90.1
(Bender, 2015) (Amsili & Seminck, 2017)	Expérience sur des sujets humains	92.1 en anglais, 93.6 en français

Tableau 1 : Évolution de performance sur les schémas Winograd et la technique utilisée

A la lumière de ces résultats récents, j'ai mené des expériences pendant mon stage au Lattice avec Camembert (Martin et al., 2019) sur les schémas Winograd en français. Le gain de performance apporté par les modèles pré-entraînés a été considérable (76% en termes d'exactitude versus 53.63 % dans (Amsili & Seminck, 2017a)). La performance état de l'art est donc augmentée de 22%. Cependant il a été constaté que le modèle entraîné est peu robuste dans le sens où un switch de mots-clés dans les schémas n'entraîne pas un switch de réponses. Par ailleurs, ce manque de robustesse peut être aussi induit en cas de simples variations linguistiques (temps, nombre, genre etc.). La Figure ci-dessous illustre un des cas où la robustesse du système est mise en question :

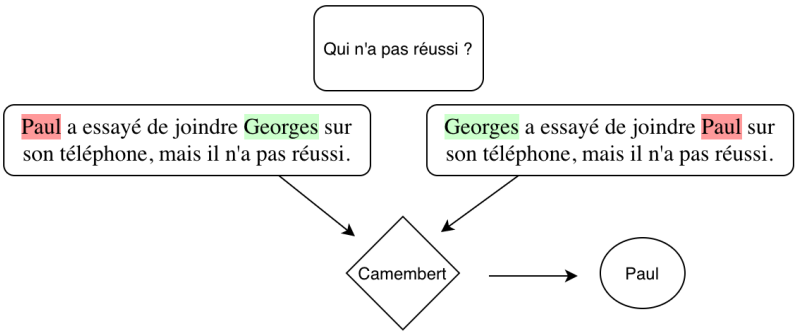

Figure 1 : Manque de robustesse du système de classification en cas de switch.

Ces résultats suggèrent que les prédictions des modèles neuronaux du type Bert ne sont pas capables de traiter des variations des schémas Winograd.

Il est donc intéressant d'investiguer sur la façon dont ces modèles neuronaux contextuels encodent les connaissances linguistiques et extra-linguistiques. A cet effet plusieurs méthodes peuvent être utilisées dont entre autres des méthodes basées sur des perturbations d'input telles que LIME (Ribeiro et al., 2016) ou des méthodes basées sur les gradients (Adebayo et al., 2020). Il serait aussi intéressant de relancer la lignée d'études commencée par (Emami, De La Cruz, et al., 2018) qui vise à mieux résoudre les schémas avec des techniques d'extraction d'information. Cette approche se propose de reformaliser les items Winograd sur la base d'une annotation de rôles sémantiques et elle est par définition plus robuste face à des variations aussi bien linguistiques que structurelles. De récentes études (Trichelair et al., 2018) montrent déjà l'avantage de la méthode sémantique, bien que la performance de cette dernière laisse encore à désirer (57.1 % d'exactitude).

Références

Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., & Kim, B. (2020). Sanity Checks for Saliency Maps. *ArXiv:1810.03292 [Cs, Stat]*. http://arxiv.org/abs/1810.03292

Amsili, P., & Seminck, O. (2017). *Schémas Winograd en français: Une étude statistique et comportementale*.

Bender, D. (2015). Establishing a Human Baseline for the Winograd Schema Challenge. *MAICS*, 39–45.

Emami, A., De La Cruz, N., Trischler, A., Suleman, K., & Cheung, J. C. K. (2018). A Knowledge Hunting Framework for Common Sense Reasoning. *ArXiv:1810.01375 [Cs]*.

Emami, A., Trischler, A., Suleman, K., & Cheung, J. C. K. (2018). A generalized knowledge hunting framework for the winograd schema challenge. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Student Research Workshop*, 25–31.

Kocijan, V., Cretu, A.-M., Camburu, O.-M., Yordanov, Y., & Lukasiewicz, T. (2019). A Surprisingly Robust Trick for Winograd Schema Challenge. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 4837–4842.

Liu, Q., Jiang, H., Ling, Z.-H., Zhu, X., Wei, S., & Hu, Y. (2016). Commonsense knowledge enhanced embeddings for solving pronoun disambiguation problems in Winograd Schema Challenge. *ArXiv Preprint ArXiv:1611.04146*.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. *ArXiv Preprint ArXiv:1907.11692*.

Martin, L., Muller, B., Suárez, P. J. O., Dupont, Y., Romary, L., de la Clergerie, É. V., Seddah, D., & Sagot, B. (2019). Camembert: A tasty french language model. *ArXiv Preprint ArXiv:1911.03894*.

Rahman, A., & Ng, V. (2012). Resolving complex cases of definite pronouns: The winograd schema challenge. *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning*, 777–789.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. *ArXiv:1602.04938 [Cs, Stat]*. http://arxiv.org/abs/1602.04938

Sakaguchi, K., Le Bras, R., Bhagavatula, C., & Choi, Y. (2020). WinoGrande: An Adversarial Winograd Schema Challenge at Scale. *Proceedings of the AAAI Conference on Artificial Intelligence*, *34*(05), 8732–8740.

Trichelair, P., Emami, A., Cheung, J. C. K., Trischler, A., Suleman, K., & Diaz, F. (2018). On the evaluation of common-sense reasoning in natural language understanding. *ArXiv Preprint ArXiv:1811.01778*.

Trinh, T. H., & Le, Q. V. (2018). A simple method for commonsense reasoning. *ArXiv Preprint ArXiv:1806.02847*.