Pascal Amsili
Université Sorbonne Nouvelle, ILPGA
19, rue des Bernardins 75005 Paris

24 novembre 2020

J'ai choisi de soutenir, avec beaucoup d'enthousiasme, la demande de bourse de Master présentée par **Xiaoou Wang** au labex EFL, d'une part parce que c'est lui qui a présenté le projet le plus élaboré et le plus pertinent parmi les étudiants qui m'ont contacté, mais surtout parce que je suis convaincu que ce projet, qui s'inscrit de façon très évidente dans le cadre de l'opération « Schémas Winograd » de l'axe 5, dont je suis responsable, va nous permettre de faire des progrès significatifs dans cette recherche que je mène (avec plusieurs collaborateurs) depuis plusieurs années.

Il s'agit de mettre à profit les recherches récentes sur les plongements lexicaux et leur utilisation dans des « modèles de langue », pour tenter d'obtenir des bonnes performances sur la résolution des anaphores dans le cadre des schémas Winograd en français. Nos propres recherches en 2018, avec O. Seminck et V. Segonne (Taln 19), qui utilisaient la génération précédente de modèles de langue, avaient abouti à une conclusion décevante, mais depuis, les travaux de la communauté internationale sur la même tâche ont montré des progrès significatifs avec les modèles de dernière génération (modèles BERT), au point d'atteindre dans certains cas une performance humaine. Or des ressources comparables existent dorénavant pour le français, et par ailleurs nous sommes en train d'enrichir le jeu de données du français (publication de la version 2 prévue fin décembre).

Ce projet est particulièrement bienvenu au laboratoire Lattice où se trouvent regroupées plusieurs personnes compétentes et intéressées par le projet Winograd, au point qu'en plus de l'opération de l'axe 5 du labex EFL, j'ai récemment mis en place un groupe de travail, co-animé par Olga Seminck, actuellement en contrat post-doctoral au labo, avec qui nous avons initié ce projet il y a quelques années, au laboratoire LLF.

Je connais **Xiaoou Wang** depuis l'année scolaire 2019/10, au cours de laquelle il a assisté à mon cours d'algorithmique (avec une note de 17,6 il fait partie des 5 meilleurs de la promotion). J'ai pu apprécier sa maturité et sa participation pendant mes enseignements (y compris le cours de Sémantique computationnelle que je donne actuellement), et j'ai aussi été frappé de son autonomie lors de la préparation de cette candidature où j'ai constaté qu'il avait assimilé la littérature scientifique de manière efficace et pertinente. Je n'ai aucun doute qu'il va pouvoir mener à bien le projet qu'il présente aujourd'hui, et j'ai toute confiance dans le fait que ce mémoire de M2 pourrait constituer une base pour une éventuelle thèse dans le cadre général du projet Winograd.

Je voudrais ajouter que la performance sur le *benchmark* des schémas Winograd est certes un résultat appréciable et qui donnera lieu à publication, mais ce n'est pas le seul but de cette recherche qui vise à éclairer de façon plus fondamentale — et à plus long terme — la façon dont les modèles neuronaux encodent les connaissances linguistiques et extra-linguistiques.

Tél +33 (0)1 44 32 05 70 ; Fax - 73 ; pascal.amsili@ens.fr ; http://www.linguist.univ-paris-diderot.fr/~amsili